Natural Language Processing – 3rd Assignment

Γεώργιος Βιδάκης [f3322402] Γεώργιος Φακίδης [f3322409] Πέτρος Φίλος [f3322410]

- Link 9ης Άσκησης  Link 10ης Άσκησης

Στη δέκατη άσκηση έχουμε ασχοληθεί με το "dataset" που αποκαλείται "universal dependencies" και το οποίο περιέχει δεδομένα από την αγγλική γλώσσα. Ο σκοπός μας είναι να μπορέσουμε να αναγνωρίσουμε τι μέρος του λόγου είναι κάθε μία από τις εμφανιζόμενες λέξεις "tokens" εντός του συγκεκριμένου συνόλου δεδομένων το οποίο προέρχεται από ένα αμερικάνικο πανεπιστήμιο το οποίο προέβη σε συντακτική επισήμανση ανοικτά διαθέσιμων κειμένων. Αντλήσαμε τα δεδομένα μας μέσω κάποιων αρχείων στα οποία αποκτήσαμε πρόσβαση μέσω ενός ανοικτού αποθετηρίου. Στη συγκεκριμένη περίπτωση τα δεδομένα ήταν ήδη διασπασμένα σε δεδομένα εκπαίδευσης (πλήθος 9520), δεδομένα ανάπτυξης (πλήθος 1341) και τέλος σε δεδομένα ελέγχου (πλήθος 1285). Ακολούθως τα μετατρέπουμε σε μορφή βολική για εμάς όσον αφορά την επεξεργασία και στη συνέχεια προετοιμαζόμαστε με σκοπό να εκμεταλλευτούμε το εργαλείο "word2vec" το οποίο είναι ένα διάσημο εργαλείο το οποίο μπορεί να παράγει μέσω μεγάλων συνόλων δεδομένων, καλής ποιότητας διανύσματα "word embeddings". Η δομή η οποία συναντήθηκε ήταν πολλές λίστες στις οποίες περιέχονταν οι λέξεις μιας πρότασης συνοδευόμενες και από το αντίστοιχο "pos tag" το οποίο αφορούσε το μέρος του λόγου στο οποίο ανήκει η συγκεκριμένη λέξη. Συνολικά είχαμε "17" διαφορετικές κατηγορίες "part of speech". Φτάνοντας στο σημείο στο οποίο επρόκειτο να παράξουμε τα "word embeddings", συναντήσαμε τη περίπτωση για κάποιες λέξεις να μην συμπεριλαμβάνονται στο αντίστοιχο λεξιλόγιο του "word2vec" και αποφασίσαμε ως λύση να ορίσουμε για αυτά ένα αυθαίρετο μηδενικό διάνυσμα, έτσι ώστε να μπορέσουμε να εναρμονιστούμε με τα μεγέθη που πρέπει να τηρούνται κατά τις διαδικασίες που έχει εντός του μηχανισμού του το "pytorch". Όπως και στη πρώτη εργασία επιλέξαμε λόγω της ευρείας απήχησης που παρουσιάσει η συνάρτηση "RELU" να την χρησιμοποιήσουμε, όπως και κάποια επίπεδα "dropout" εντός του δικτύου με "μέτριες" πιθανότητες. Γενικότερα σε σχέση και με τη πρώτη εργασία έχουμε δώσει μεγαλύτερα μεγέθη όσον αφορά τους πίνακες των υπολογισμών και αυτό έχοντας υπόψη μας κάποιες φήμες σχετικά με το ότι τα "word embeddings" μπορεί να μην τα πάνε και τόσο καλά στη συγκεκριμένη περίπτωση, αναλογικά με το εάν πηγαίνουμε και υιοθετούσαμε κάποια άλλα από τα "baseline" μοντέλα που ήδη γνωρίζουμε. Ως πλήθος εποχών αποφασίσαμε να παραμείνουμε στο "150" και να μην ανεβούμε πιο ψηλά, λόγο αυτών που αναφέραμε προηγουμένως σχετικά με τα μεγέθη των ενδιάμεσων επιπέδων "hidden layers" του νευρωνικού μας δικτύου. Όσον αφορά τώρα τα δεδομένα μας παρατηρήσαμε:

| | precision | recall | f1-score | support |
|---|---|---|---|---|
| PART | 1.00 | 0.30 | 0.46 | 661 |
| PRON | 0.92 | 0.96 | 0.94 | 2279 |
| ADJ | 0.88 | 0.90 | 0.89 | 1584 |
| X | 0.75 | 0.25 | 0.38 | 12 |
| VERB | 0.90 | 0.85 | 0.88 | 2676 |
| ADP | 0.86 | 0.64 | 0.73 | 2226 |
| ADV | 0.91 | 0.79 | 0.84 | 1150 |
| INTJ | 0.84 | 0.66 | 0.74 | 256 |
| PUNCT | 0.52 | 1.00 | 0.69 | 3180 |
| SCONJ | 0.83 | 0.36 | 0.50 | 405 |
| NOUN | 0.89 | 0.92 | 0.90 | 3986 |
| DET | 0.94 | 0.75 | 0.83 | 1896 |
| AUX | 0.91 | 0.87 | 0.89 | 1353 |
| PROPN | 0.79 | 0.56 | 0.66 | 1029 |
| CCONJ | 0.97 | 0.27 | 0.42 | 828 |
| SYM | 1.00 | 0.13 | 0.24 | 15 |
| NUM | 0.92 | 0.48 | 0.63 | 384 |
| accuracy | | | 0.80 | 23920 |
| macro avg | 0.87 | 0.63 | 0.68 | 23920 |
| weighted avg | 0.85 | 0.80 | 0.80 | 23920 |

```
MLP Validation Accuracy: 80.06%
MLP Test Accuracy:78.17%
```

Επιπρόσθετα παρατηρήσαμε τα ακόλουθα διαγράμματα:

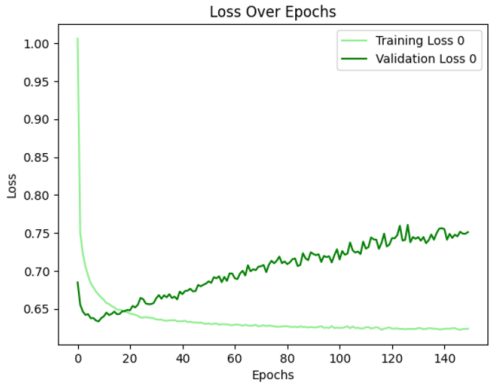


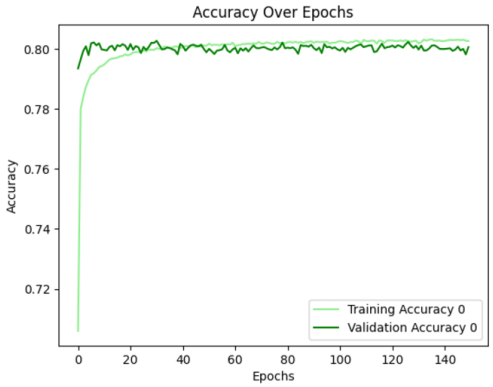


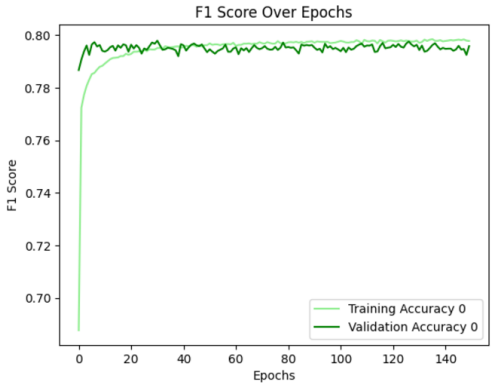


Από την άλλη στην έναται άσκηση έχουμε πάρει και πάλι το σύνολο δεδομένων που είχαμε χρησιμοποιήσει και στη προηγούμενη εργασία. Εκεί είχαμε μια περίπτωση "binary classification" όπου προσπαθούσαμε να κατατάξουμε κάποιες αξιολογήσεις ταινιών ως "υποκειμενικές" ή "αντικειμενικές". Για τα χαρακτηριστικά της υλοποίησης δεν έχουμε διαφοροποιηθεί κάπως όσον αφορά την υλοποίηση του πλέον "baseline" μας μοντέλου που είναι το μοντέλο της λογιστικής παλινδρόμησης. Μια μεγάλη διαφορά είναι ότι έχοντας στο μυαλό μας την έρευνα για εύρεση καλών υπερπαραμέτρων, φροντίσαμε αρχικά σε πρώτο στάδιο να κάνουμε μια διάσπαση σε δεδομένα εκπαίδευσης (ποσοστό 70%) και σε δεδομένα ελέγχου (ποσοστό 30%). Όμως για να μπορέσουμε να αποκτήσουμε και δεδομένα ανάπτυξης (development data), προβήκαμε και σε μία περαιτέρω διάσπαση η οποία αφορούσε τα δεδομένα εκπαίδευσης. Το αντίστοιχο "70%" ποσοστό έσπασε στα νέα δεδομένα ελέγχου (ποσοστό 80%) και στα δεδομένα ανάπτυξης (20%). Για το "baseline" μοντέλο μας λοιπόν παρατηρήσαμε τις εξής μετρικές:

| | precision | recall | f1-score | support |
|---|---|---|---|---|
| subj | 0.89 | 0.82 | 0.86 | 708 |
| obj | 0.83 | 0.90 | 0.87 | 692 |
| accuracy | | | 0.86 | 1400 |
| macro avg | 0.86 | 0.86 | 0.86 | 1400 |
| weighted avg | 0.86 | 0.86 | 0.86 | 1400 |

Υπενθυμίζουμε πως σε αυτό το σημείο δεν θα χρειαστεί να κοιτάξουμε τα δεδομένα για όλες τις κατηγορίες, αλλά μόνο για τη "majority class" η οποία όπως γνωρίζουμε είναι η κατηγορία η οποία είναι περισσότερο σπάνια. Τώρα όσον αφορά το κύριο μας μοντέλο έχουμε ένα "multi-layer perceptron" στο οποίο έχουμε ακολουθήσει ως προς τη δομή, τη διαδικασία του "ρόμβου" η οποία προτάθηκε κατά τη διάρκεια του φροντιστηρίου. Αυτό σημαίνει ότι ξεκινάμε με κάποια μικρότερα μεγέθη πίνακα (από το επίπεδο εισόδου), τα αυξάνουμε ενδιάμεσα για ένα διάστημα μέχρι να καταλήξουμε να τα ξανά μειώσουμε φτάνοντας στο επίπεδο εξόδου. Θα πρέπει να τονίσουμε πως για τις ανάγκες του "hyperparameter tuning" έχουμε πάει στο κατασκευαστή του νευρωνικού μας δικτύου τύπου "perceptron" και έχουμε προσθέσει κάποιες επιπλέον παραμέτρους οι οποίες μας επιτρέπουν να επαναλαμβάνουμε διαδοχικά τη διαδικασία του "forward" και του "backward pass". Αυτό μας επέτρεψε να αξιολογήσουμε και το μοντέλο μας με διαφορετικές τιμές στις υπερπαραμέτρους, ιδιαίτερα όσον αφορά τα μεγέθη των πινάκων στο νευρωνικό αλλά και για παράδειγμα όσον αφορά τη πιθανότητα του να περιλαμβάνουμε ή όχι κάθε φορά έναν νευρώνα στους υπολογισμούς μας (dropout). Για το "κύριο" μας λοιπόν παρατηρήσαμε τις εξής μετρικές:

| | precision | recall | f1-score | support |
|---|---|---|---|---|
| subj | 0.89 | 0.85 | 0.87 | 708 |
| obj | 0.85 | 0.89 | 0.87 | 692 |
| accuracy | | | 0.87 | 1400 |
| macro avg | 0.87 | 0.87 | 0.87 | 1400 |
| weighted avg | 0.87 | 0.87 | 0.87 | 1400 |

Και όσον αφορά το "accuracy" μεταξύ των δύο μοντέλων παρατηρήσαμε:

```
Logistic Regression Validation Accuracy: 86.21%
Logistic Regression Test Accuracy:86.40%

MLP TF-IDF Validation Accuracy: 87.07%
MLP TF-IDF Test Accuracy:85.40%
```

Και τέλος όσον αφορά τις συγκρίσεις των δύο υλοποιήσεων όσων αφορά τις κυριότερες δοκιμές μας ως προς τις τιμές των υπερπαραμέτρων, παρατηρήσαμε τα παρακάτω:
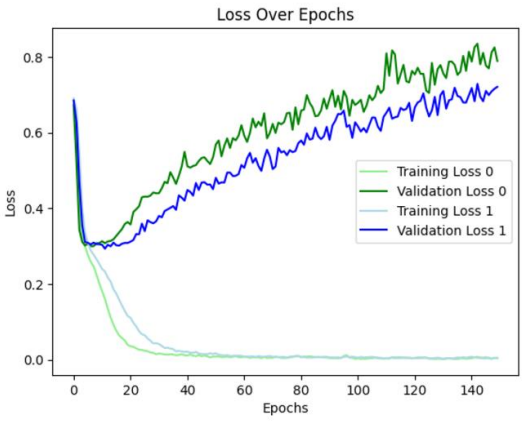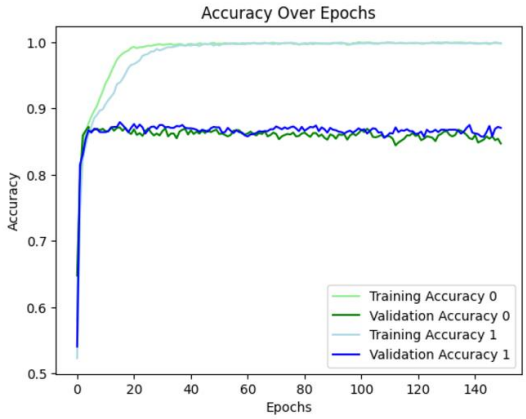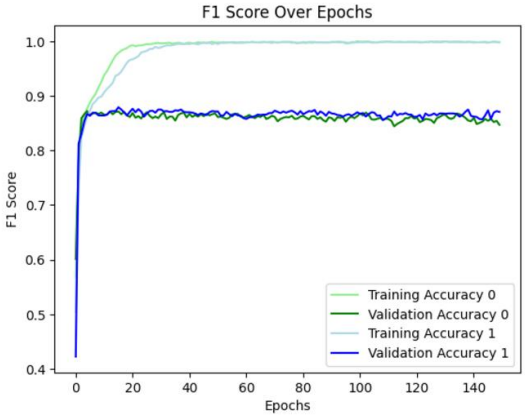
(τονίζουμε πως με αποχρώσεις ιδίου χρώματος απεικονίζονται "errors" που αφορούν τον ίδιο συνδυασμό)