Natural Language Processing – 4th Assignment

Γεώργιος Βιδάκης [f3322402] Γεώργιος Φακίδης [f3322409] Φίλος Πέτρος [f3322410]

- Link 1ης Άσκησης Link 2ης Άσκησης

Αρχικά στη πρώτη εργασία ασχολούμαστε με το σύνολο δεδομένων το οποίο αφορούσε τη περίπτωση κάποιων αξιολογήσεων (reviews) σε δύο κατηγορίες όπου η πρώτη κατηγορία σχετιζόταν με την υποκειμενικότητα ενός σχολίου (subjectivity) και η δεύτερη κατηγορία σχετιζόταν με την αντικειμενικότητα (objectivity). Το συγκεκριμένο πρόβλημα ήταν τύπου "binary classification" και "single label", δηλαδή κάθε "review" μπορούσε να ανήκει σε μόνο μία από τις δυνατές κατηγορίες. Υπενθυμίζουμε πως σε αυτή τη περίπτωση έχουμε τη δυνατότητα να εστιάσουμε περισσότερο στη "minority" κατηγορία, δηλαδή στη κατηγορία η οποία είναι η πιο δύσκολη από τις δύο. Η δυνατότητα να εστιάσουμε περισσότερο σε μία μόνο από τις κατηγορίες στα "binary classification" προβλήματα, όπου οι κατηγορίες είναι και αμοιβαία αποκλειόμενες πηγάζει από το γεγονός πως εάν τα πηγαίνουμε καλά στη μία κατηγορία, τότε αναγκαστικά θα τα πηγαίνουμε καλά και στην άλλη. Πρώτα, όπως και στις προηγούμενες εργασίες ξεκινάμε και κάνουμε "pos tagging" και "lemmatization" έτσι ώστε να συγκεκριμενοποιήσουμε αποδοτικότερα τα νοήματα λέξεων που τυγχάνει να εμφανίζονται σε διαφορετικές συντακτικές μορφές. Αντίστοιχα προβαίνουμε στη συνηθισμένη προεπεξεργασία (preprocessing) των δεδομένων, όπως για παράδειγμα στην αφαίρεση των σημείων στίξης (punctuations). Ακολούθως προβαίνουμε σε διάσπαση των δεδομένων (data splitting) όπου σε πρώτο στάδιο διασπάμε τα δεδομένα μας σε δεδομένα εκπαίδευσης (training data) σε ποσοστό 70% και σε δεδομένα ελέγχου (test data) σε ποσοστό 30%. Ακολούθως για να μπορέσουμε να διαμορφώσουμε και τις υπερπαραμέτρους των πιο σύνθετων μοντέλων που θα χρησιμοποιήσουμε, προβαίνουμε και σε μία περαιτέρω δευτερεύουσα διάσπαση του ποσοστού των δεδομένων εκπαίδευσης, σε δεδομένα εκπαίδευσης με ποσοστό 80% και σε δεδομένα ανάπτυξης (development data) με ποσοστό 20%. Επειδή τώρα θα χρησιμοποιήσουμε ως απλοϊκά (baseline) μοντέλα, ένα "dummy classifier", ένα "logistic regression" και ένα μοντέλο "Multi-Layer Perceptron" με ιδιότητες (features) τα διανύσματα με συνιστώσες "TF/IDF", πηγαίνουμε και χρησιμοποιούμε ένα "vectorizer" του αντίστοιχου τύπου όπου μεριμνούμε να κάνουμε και "feature extraction" έχοντας ως μέγιστο τα πέντε χιλιάδες αλλά και "feature selection" μέσω του "SVD" στις τριακόσιες συνιστώσες για τα διανύσματα. Για αυτά τα μοντέλα παρατηρούμε τα παρακάτω αποτελέσματα για τις μετρικές, όπου για "MLPs" έχουμε εξετάσει τα τρία μοντέλα όπως φαίνονται παρακάτω με διαφορετικά μεγέθη, τα μεγέθη του πρώτου και του δεύτερου "hidden layer" και το "dropout ratio":

MLP 1st Version [512, 128, 0.4] MLP 2nd Version [256, 64, 0.3] MLP 3rd Version [128,64,0.2]

Training Data		Precision	Recall	F1	Macro Precision	Macro Recall	Macro F1	Accuracy
dummy (majority)	subjective	0.00	0.00	0.00	0.26	0.50	0.34	0.51
	objective	0.51	1.00	0.68	0.26	0.51	0.34	
logistic regression	subjective	0.88	0.86	0.87	0.88	0.88	0.88	0.88
	objective	0.87	0.89	0.88	0.88	0.88	0.88	
MLP *(1st version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
MLP *(2nd version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
MLP *(3rd version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
Development Data		Precision	Recall	F1	Macro Precision	Macro Recall	Macro F1	Accuracy
dummy (majority)	subjective	0.00	0.00	0.00	0.25	0.50	0.33	0.49
	objective	0.49	1.00	0.66	0.24	0.49	0.33	
logistic regression	subjective	0.89	0.82	0.86	0.86	0.86	0.86	0.86
	objective	0.83	0.90	0.87	0.86	0.86	0.86	
MLP *(1st version)*	subjective	0.87	0.85	0.86	0.86	0.86	0.86	0.86
	objective	0.85	0.87	0.86	0.86	0.86	0.86	
MLP *(2nd version)*	subjective	0.88	0.84	0.86	0.86	0.86	0.86	0.86
	objective	0.84	0.88	0.86	0.86	0.86	0.86	
MLP *(3rd version)*	subjective	0.86	0.86	0.86	0.86	0.86	0.86	0.86
	objective	0.85	0.86	0.86	0.86	0.86	0.86	

Testing Data		Precision	Recall	F1	Macro Precision	Macro Recall	Macro F1	Accuracy
dummy (majority)	subjective	0.00	0.00	0.00	0.24	0.50	0.33	0.48
	objective	0.48	1.00	0.65	0.23	0.48	0.31	
logistic regression	subjective	0.88	0.86	0.87	0.86	0.86	0.86	0.86
	objective	0.85	0.87	0.86	0.86	0.86	0.86	
MLP *(1st version)*	subjective	0.86	0.86	0.86	0.86	0.86	0.86	0.86
	objective	0.85	0.85	0.85	0.86	0.86	0.86	
MLP *(2nd version)*	subjective	0.86	0.87	0.86	0.86	0.86	0.86	0.86
	objective	0.86	0.85	0.85	0.86	0.86	0.86	
MLP *(3rd version)*	subjective	0.86	0.86	0.86	0.85	0.85	0.85	0.85
	objective	0.85	0.84	0.85	0.85	0.85	0.85	

Για τα διαγράμματα που αφορούσαν τη μεταβολή των σφαλμάτων με το πέρασμα των εποχών (loss over epochs) για τη περίπτωση των "Multi-Layer Perceptrons" είχαμε τα παρακάτω. Προφανώς μπορούμε να διαλέξουμε ένα μοντέλο από τα τρία με βάση το ποιο είναι το καλύτερο "development loss" στη αντίστοιχη στιγμή όπου έχουμε παρατηρήσει την ύπαρξη του καλύτερου μέχρι τότε "checkpoint" και ενδεχομένως έχοντας και κάποια υπομονή (patience).

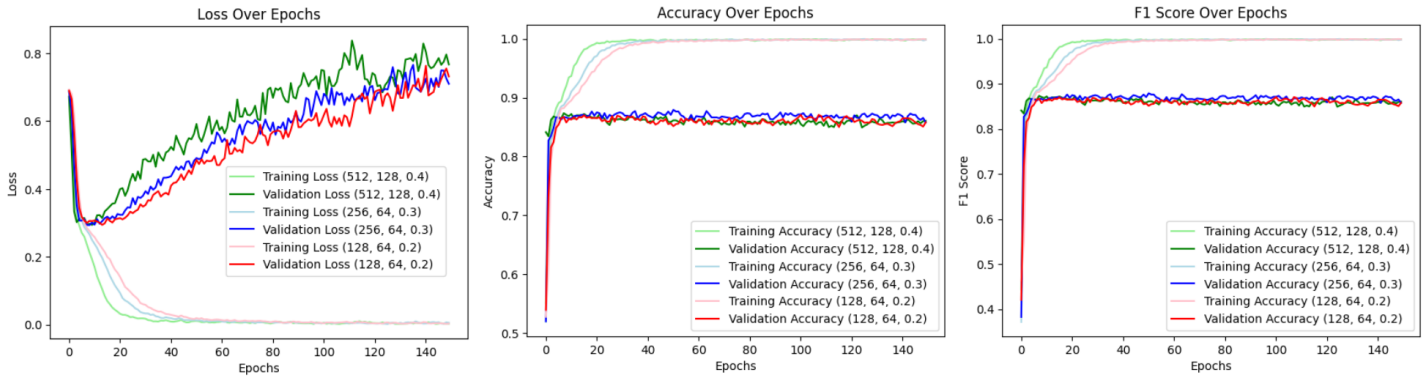

Το συμπέρασμα από όλα τα παραπάνω "baseline" μοντέλα που εξετάσαμε είναι ότι καλύτερα θα ήταν να κρατήσουμε τα "MLPs" που μπορούν να μεταβαίνουν στις μεγαλύτερες από τις διαθέσιμες δοκιμαζόμενες διαστάσεις, έτσι ώστε να έχουμε κάτι ισχυρό στη διάθεση μας για να συγκρίνουμε το δίκτυο "RNN" που επρόκειτο να κατασκευάσουμε στη συνέχεια.

Στη συνέχεια περνάμε στο κομμάτι το οποίο αφορά το κύριο (main) μας μοντέλο για τη συγκεκριμένη εργασία όπου θα είναι ένα μοντέλο "RNN" τύπου "bidirectional" με κελιά "GRU". Στη συγκεκριμένη περίπτωση θα δουλέψουμε με "word embeddings", οπότε εκμεταλλευόμαστε το "gensim" για τη παραγωγή τους και προβαίνουμε στη κατασκευή μιας κλάσης (class) όπου μεριμνούμε εκτός από την κληρονόμηση του αντίστοιχου "pytorch" αντικειμένου, για το πέρασμα κάποιων παραμέτρων οι οποίες θα μας βοηθήσουν στη διαμόρφωση του εσωτερικού τμήματος του μοντέλο. Για παράδειγμα μέσω αυτών των παραμέτρων έχουμε καταφέρει να δοκιμάσουμε κάποιες υπερπαραμέτρους οι οποίες αφορούν τις διαστάσεις του "hidden layer", τις διαστάσεις για το τύπο κελιού "gru" και τα επίπεδα στοιβάγματος (stacks). Από αυτές τις δοκιμές προέκυψαν τα παρακάτω διαγράμματα:

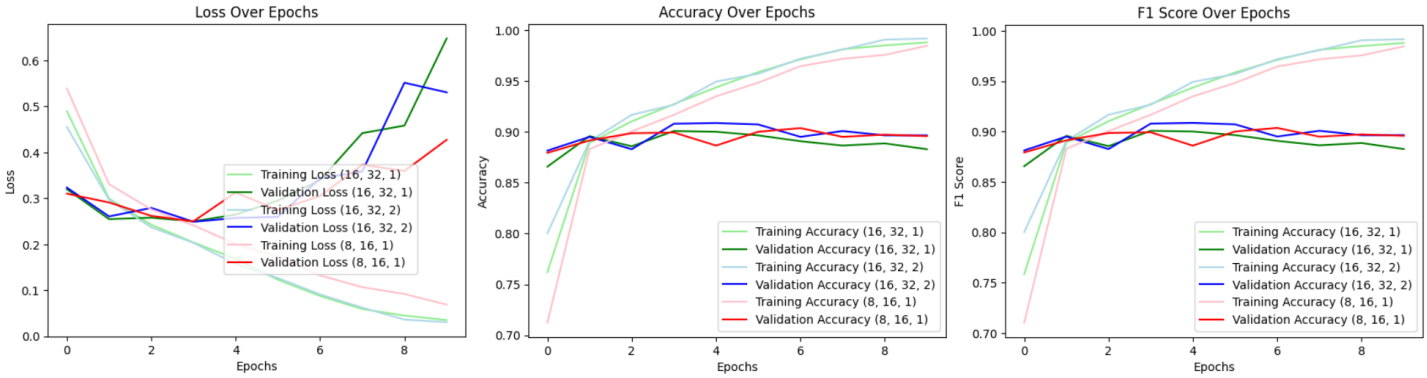

Από την άλλη όσον αφορά τις μετρικές για τα τρία "RNN" μοντέλα που δοκιμάσαμε παρατηρήσαμε τα εξής παρακάτω:

RNN 1st Version [16, 32, 1] RNN 2nd Version [16, 32, 2] RNN 3rd Version [8, 16, 1]

Training Data		Precision	Recall	F1	Macro Precision	Macro Recall	Macro F1	Accuracy
RNN *(1st version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
RNN *(2nd version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
MLP *(3rd version)*	subjective	1.00	1.00	1.00	1.00	1.00	1.00	1.00
	objective	1.00	1.00	1.00	1.00	1.00	1.00	
Development Data		**Precision**	**Recall**	**F1**	**Macro Precision**	**Macro Recall**	**Macro F1**	**Accuracy**
RNN *(1st version)*	subjective	0.85	0.93	0.89	0.88	0.88	0.88	0.88
	objective	0.92	0.83	0.87	0.88	0.88	0.88	
RNN *(2nd version)*	subjective	0.89	0.90	0.90	0.90	0.90	0.90	0.90
	objective	0.90	0.89	0.89	0.90	0.90	0.90	
RNN *(3rd version)*	subjective	0.91	0.88	0.90	0.90	0.90	0.90	0.90
	objective	0.88	0.91	0.90	0.90	0.90	0.90	
Testing Data		**Precision**	**Recall**	**F1**	**Macro Precision**	**Macro Recall**	**Macro F1**	**Accuracy**
RNN *(1st version)*	subjective	0.84	0.93	0.88	0.87	0.87	0.87	0.87
	objective	0.91	0.81	0.86	0.87	0.87	0.87	
RNN *(2nd version)*	subjective	0.87	0.90	0.88	0.88	0.88	0.88	0.88
	objective	0.89	0.85	0.87	0.88	0.88	0.88	
RNN *(3rd version)*	subjective	0.90	0.87	0.89	0.88	0.88	0.88	0.88
	objective	0.87	0.90	0.88	0.88	0.88	0.88	

Από τα παραπάνω αποτελέσματα βλέπουμε πως το "recurrent neural networks" φαίνεται να τα πηγαίνουν καλύτερα από όλα τα "baseline" μοντέλα που εξετάσαμε προηγουμένως και μάλλον λόγω των λίγων εποχών που πραγματοποιήσαμε αυτή τη φορά τα πειράματα, αφού ήταν μόνο δέκα, φαίνεται να μην προκύπτει μια τελείως ξεκάθαρη εικόνα για το ποιο είναι το μοτίβο που να οδηγεί με βάση αυτού του συγκεκριμένου είδους τα δεδομένα σε κάτι που να πηγαίνει καλά, αλλά παρόλα αυτά θα μπορούσαμε να προβούμε στον ισχυρισμό πως τα επίπεδα στοιβάγματος δείχνουν να λειτουργούν υπέρ μας.

Τώρα όσον αφορά τη δεύτερη άσκηση, εκεί περνάμε πλέον στο πρόβλημα του "pos tagging" όπου προσπαθούμε να προβλέψουμε τι μέρος του λόγου (part of speech) είναι μια λέξη (token) της συλλογής κειμένων που αποτελεί στο "universal dependencies". Σε αυτό το κομμάτι θα δουλέψουμε με "word embeddings" το οποία θα τα αποκτήσουμε εκμεταλλευόμενοι το εργαλείο του "word2vec" ώστε να αποφύγουμε το να ξεκινήσουμε από τελείως τυχαία διανύσματα. Τώρα και πάλι κινούμαστε στο ίδιο επίπεδο και για τα "baseline" μοντέλα έχουμε χρησιμοποιήσει ακριβώς τα ίδια τρία που έχουμε και στη πρώτη άσκηση αυτής της εργασίας. Τώρα αυτά που έχουμε παρατηρήσει για τα "MLPs" είναι τα εξής:

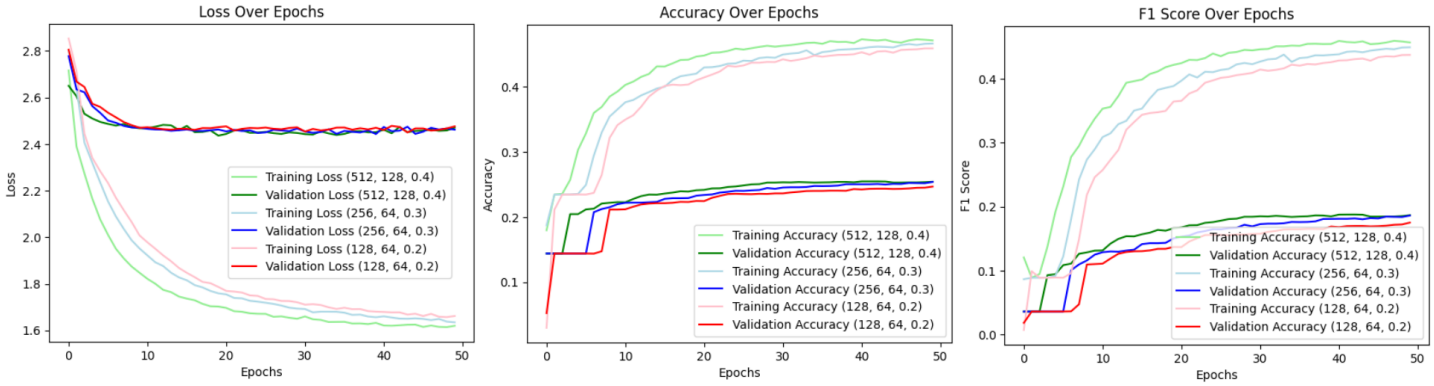

Συνοπτικά για όλα τα μοντέλα παρατηρήσαμε "accuracy" όπως φαίνεται παρακάτω:

Accuracy	Training Data	Development Data	Test Data
Dummy (majority)	23.44%	14.40%	15.22%
Logistic Regression	34.30%	17.66%	18.34%
MLP (1st Version)	47.34%	25.34%	22.04%
MLP (2nd Version)	47.16%	25.38%	22.08%
MLP (3rd Version)	46.80%	25.00%	21.92%
RNN	59.92%	28.98%	26.66%

Οπότε παρατηρούμε πως το κύριο (main) μοντέλο μας τα πηγαίνει καλύτερα από όλα τα "baseline" μοντέλα. Παρακάτω δείχνουμε και τα διαγράμματα τα οποία παράχθηκαν κατά τη διαδικασία του "hyperparameter tuning" κατά αντίστοιχο τρόπο με αυτόν της πρώτης άσκησης:

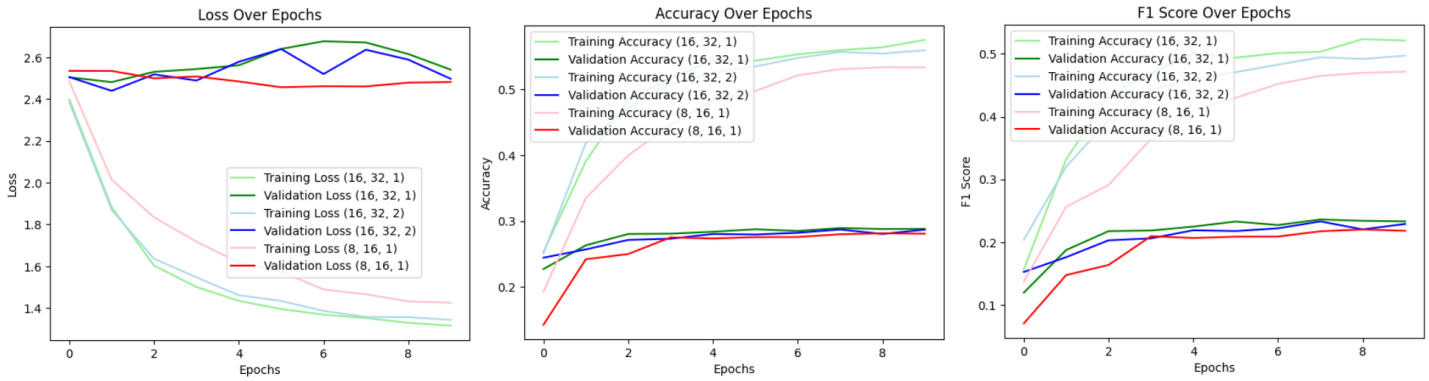

Και πάλι φαίνεται πως το μέγεθος τον διαστάσεων (dimension size) πρώτα και έπειτα και το επίπεδο στοιβάγματος (stacks) είναι χαρακτηριστικά που "ενισχύουν" το "RNN" μοντέλο μας.