Natural Language Processing – 2nd Assignment

Γεώργιος Βιδάκης [f3322402] Γεώργιος Φακίδης [f3322409] Πέτρος Φίλος [f3322410]

- Link Εργασίας

Για τη συγκεκριμένη εργασία έχουμε χρησιμοποιήσει το "dataset" από το πανεπιστήμιο του "Cornel", το οποίο είναι ένα από τα προτεινόμενα στην εκφώνηση. Ειδικότερα, αυτό το "dataset" συμπεριλαμβάνεται στο "nltk.corpus" και πρόκειται για ένα σύνολο από "reviews" ταινιών τα οποία κατατάσσονται ως "subjective" ή "objective". Αυτό σημαίνει πως έχουμε ένα "binary classification" και άρα μπορούμε να περιοριζόμαστε λίγο σχετικά με το τι απαιτείται να κοιτάμε αφού υπάρχει η δυνατότητα για μεγαλύτερη εστίαση στη "majority" κατηγορία. Αυτό συμβαίνει διότι αν τα πηγαίνουμε καλά στην κατηγορία των υποκειμενικών αξιολογήσεων, τότε αυτομάτως θα τα πηγαίνουμε καλά και στη κατηγορία των αντικειμενικών αξιολογήσεων. Αρχικά πάμε στα δεδομένα και αφού ορίσουμε τα αναγνωριστικά των δύο κατηγοριών, διαπιστώνουμε ότι η αναλογία τους είναι "50 – 50" και στη συνέχεια ξεκινάμε τη διαδικασία του "preprocessing" το οποίο κινείται παρόμοια με το αντίστοιχο φροντιστήριο. Σε πρώτο στάδιο ψάχνουμε για τα αντίστοιχα "patterns", όπως η αφαίρεση των μονών και συνεχόμενων κενών χαρακτήρων και τέλος μετατρέπουμε σε πεζά και όλα τα κεφαλαία. Από εκεί και πέρα χρησιμοποιούμε τον αντίστοιχο "lemmatizer" και μειώνουμε τα αναγνωριστικά των μερών του λόγου σε τέσσερα έτσι ώστε να μπορέσουμε να εκμεταλλευτούμε και το "wordnet". Στο τέλος αυτού του σταδίου έχουμε μια λίστα με όλα τα "strings" και μια λίστα με τα αντίστοιχα "labels" των δεδομένων μας. Στη συνέχεια σπάμε τα δεδομένων μας σε δύο μέρη και δίνουμε το 70% των δεδομένων στο κομμάτι που θα έχει το ρόλο της εκπαίδευσης και το 30% των δεδομένων στο κομμάτι που θα έχει το ρόλο της αξιολόγησης. Τονίζουμε ότι παρόλο που το σπάσιμο γίνεται τυχαία μέσω του αντίστοιχου "seed" που δίνουμε ως όρισμα, είχαμε φροντίσει να ανακατέψουμε και με ομοιόμορφο τρόπο ήδη τα δεδομένα έτσι ώστε ακόμα και χωρίς το τη τυχαία κατανομή, να διατηρείται και πάλι η αναλογία του "50 – 50" και στο κομμάτι της εκπαίδευσης, αλλά και στο κομμάτι της αξιολόγησης. Συνεχίζοντας στο κομμάτι του "feature extraction" έχουμε και πάλι κινηθεί όμοια με το εργαστήριο, αφού έχουμε επιλέξει στα διανύσματα να έχουμε ως μετρική το "tf/idf", να χρησιμοποιήσουμε εκτός από "unigrams" και "bigrams", και από όλες τις παραγόμενες "unigram" και "bigram" ιδιότητες να κρατήσουμε τις καλύτερες (πιο συχνές πιθανότατα) ιδιότητες. Αφού μετατρέψουμε λοιπόν όλα τα κείμενα σε διανύσματα. Έπειτα πηγαίνουμε και δουλεύουμε λίγο με τη μέθοδο "umap" η οποία προτάθηκε και στο εργαστήριο ως ιδανική για "virtualization" και αυτό το οποίο κάνουμε είναι ότι πηγαίνουμε από τις "5k" διαστάσεις στις "2" και κοιτάμε για το εάν τα δεδομένα εμφανίζουμε μία κάπως σχετικά ομαδοποίησης ανά κατηγορία. Αυτό παρατηρούμε ότι συμβαίνει και στο δική μας περίπτωση από το σχετικό "scatterplot":

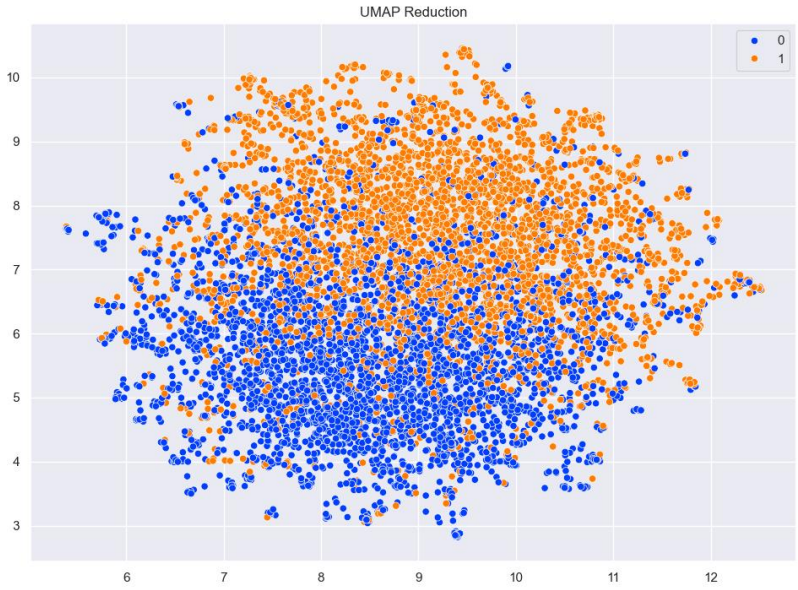

Στην συνέχεια για να μπορέσουμε να έχουμε ένα μέτρο σύγκρισης όπως αναφέρει και η εκφώνηση, πάμε και φτιάχνουμε ένα "DummyClassifier" το οποίο όπως έχει αναφερθεί είναι πολύ απλοϊκό μοντέλο που όταν του έρχεται ένα οποιοδήποτε "review" προς αξιολόγηση, κατευθείαν αποφασίζει πως ανήκει στη κατηγορία η οποία είναι η πιο συχνή στα δεδομένα με τα οποία εκπαιδεύτηκε. Από αυτό το μοντέλο μπορούμε εύκολα να διαπιστώσουμε τι κάνει μέσω της αποτύπωσης του αντίστοιχου "confusion matrix":

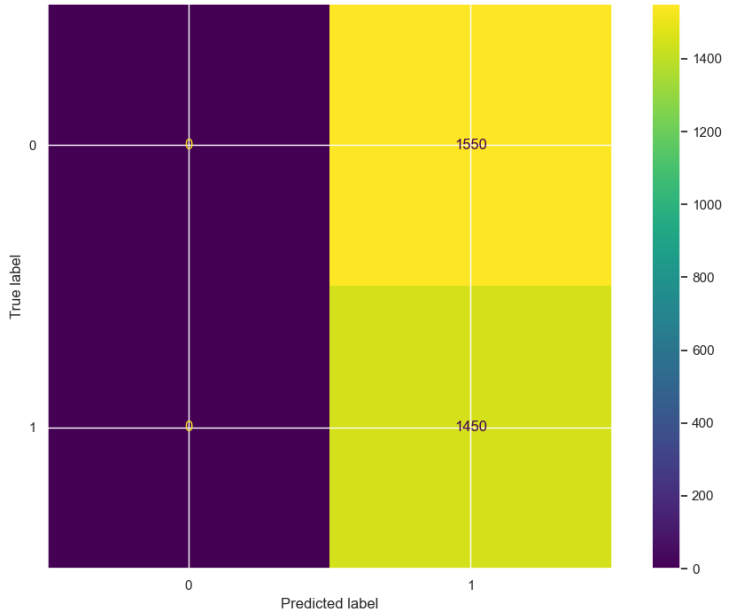

Από εκεί και πέρα πηγαίνουμε και ασχολούμαστε με ένα αντικείμενο "LogisticRegression" στο οποίο θα πάμε και θα αναπαραστήσουμε τη δικιά μας μέθοδο. Παρόμοια με το εργαστήριο χρησιμοποιούμε ως "optimizer" τον "sublinear" και στη συνέχεια αφού κάνουμε αξιολόγηση στο κομμάτι της εκπαίδευσης και στο κομμάτι της αξιολόγησης, παίρνουμε όλες τις παρακάτω μετρικές που ζητούνται από την εκφώνηση. Στις στήλες με χρώμα μπλε αποτυπώνουμε τις κλασσικές μετρικές ενώ στις στήλες με πράσινο χρώμα τις "macro average".

Training Data		Precision	Recall	F1	AUC	Precision	Recall	F1	AUC
dummy	subjective	0.00	0.00	0.00	0.75	0.5	0.25	0.34	
	objective	1.00	0.51	0.67					
logistic regression	subjective	0.94	0.94	0.94	0.98	0.94	0.94	0.94	
	objective	0.94	0.94	0.94		0.94	0.94	0.94	

Test Data		Precision	Recall	F1	AUC	Precision	Recall	F1	AUC
dummy	subjective	0.00	0.00	0.00	0.74	0.50	0.24	0.33	
	objective	1.00	0.48	0.65					
logistic regression	subjective	0.88	0.89	0.89	0.95	0.88	0.88	0.88	
	objective	0.88	0.88	0.88		0.88	0.88	0.88	

Τώρα όσον αφορά τη καμπύλη του "precision – recall" βλέπουμε πως συμφωνεί με αυτά που έχουμε αναφέρει στο μάθημα αφού παρατηρούμε πως όσο αυξάνεται το "precision" τόσο μειώνεται το "recall" και αντίστοιχα όσο αυξάνεται το "recall" τόσο μειώνεται το "precision". Αυτό είναι κάτι φυσιολογικό αφού εάν είμαστε πολύ σίγουροι τότε θα έχουμε υψηλό "precision", αλλά το "recall" θα είναι μειωμένο αφού θα χάνουμε κάποιες από τις περιπτώσεις που έπρεπε πιάσουμε για τη "majority class". Επίσης για τη "majority class" εάν φροντίσουμε να πιάνουμε όλες τις περιπτώσεις της, τότε θα έχουμε υψηλό "recall" αλλά από την άλλη πλευρά για αυτά τα οποία πιάνουμε θα έχουμε χαμηλό "precision" αφού δεν θα είμαστε και απόλυτα σίγουροι.

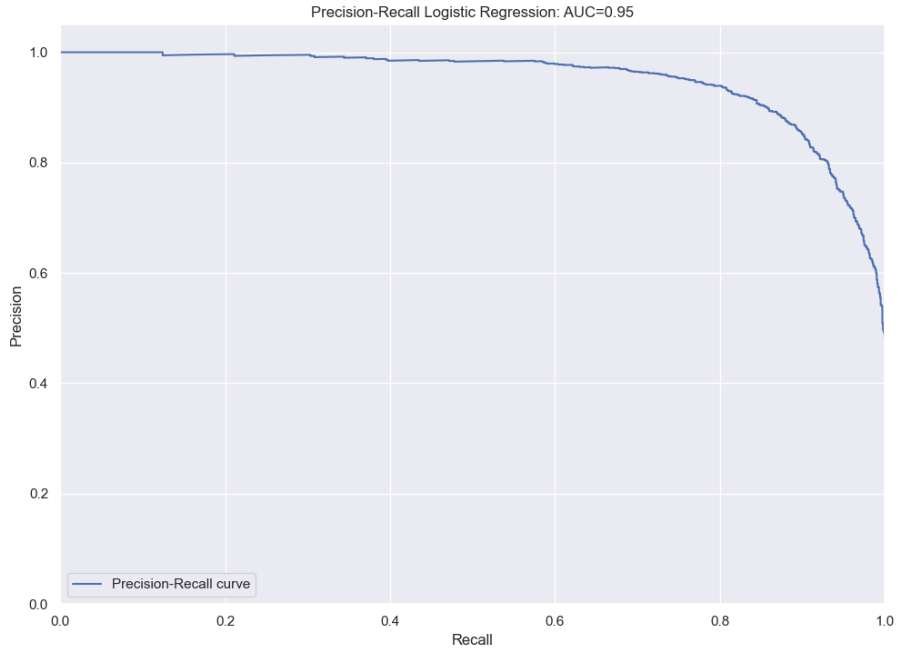

Αντίστοιχα για τη περίπτωση της "macro average" περίπτωσης των παραπάνω ποσοτήτων όπου εννοούμε πως παίρνουμε τα αποτελέσματα που έχουμε βγάλει και για τις δύο κατηγορίες και τα διαιρούμε με το πλήθος τους. Παρακάτω βλέπουμε τα διαγράμματα στα αριστερά τα "training" και δεξιά

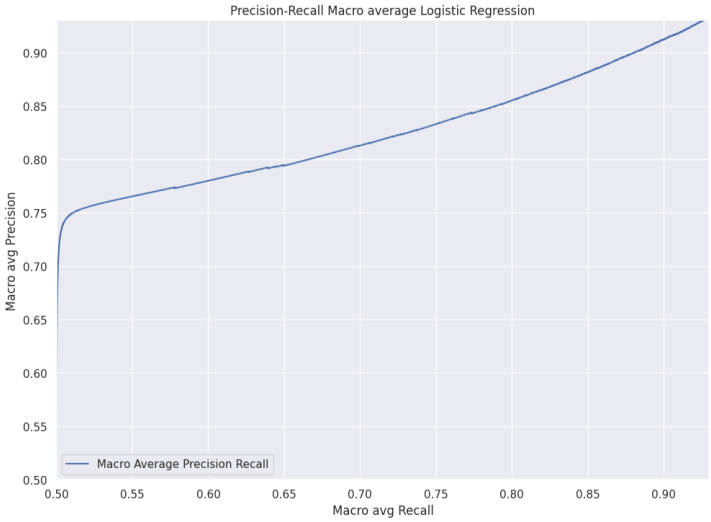

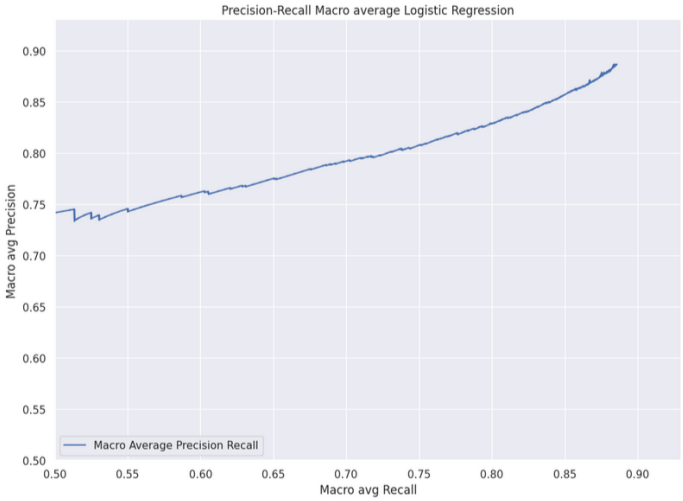
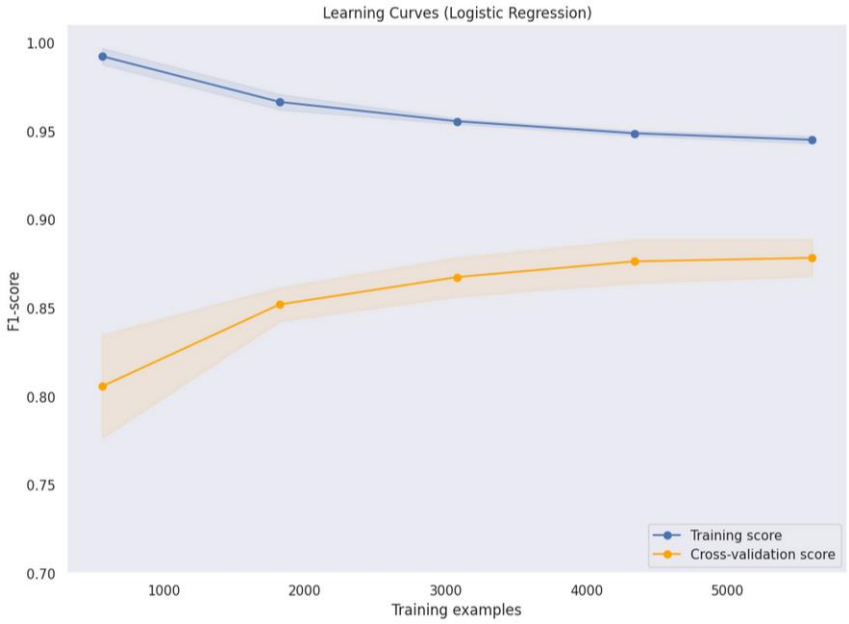
Παρόμοια και για τη "learning curve" με το "dev loss" και το "training loss" έχουμε φυσιολογικά αποτελέσματα αφού βλέπουμε πως για μεγαλύτερα σύνολα εκπαίδευσης το "dev loss" μειώνεται αφού μπορούμε πλέον όλο και περισσότερο να χειριστούμε καλά καινούργια παραδείγματα ενώ από την άλλη δυσκολευόμαστε πιο πολύ να υπερπροσαρμοστούμε στα δεδομένα εκπαίδευσης.